Árvore de Decisão para Triagem de Diabetes utilizando a Base Pima Indians Diabetes

Bétanny Alexandra[1], **Filipe Mendes**[1], **Juciane Maciel**[1]

[1]Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal do Piauí (UFPI) – Teresina – PI – Brasil

betannyalexandradasilva@gmail.com, mendesfilipe794@gmail.com,
jucianevmaciel@gmail.com

Relatório da disciplina Aprendizado de Máquina (2026.2)
Prof. Dr. Vinicius Ponte Machado

1. Introdução

Este trabalho usa a base Pima Indians Diabetes [Smith et al. 1988], composta por 768 mulheres de ascendência Pima, com 21 anos ou mais, descritas por oito variáveis clínicas. A base é bastante usada como referência na avaliação de classificadores. Ela traz, no entanto, dificuldades que influenciam diretamente os resultados: valores iguais a zero em variáveis como glicose, insulina e IMC, fisiologicamente impossíveis, que na prática representam medidas ausentes (a insulina, por exemplo, não foi medida em quase metade das pacientes); o desbalanceamento entre as classes, com cerca de 35% de pacientes diabéticas; e o número reduzido de amostras, que torna as estimativas de desempenho sensíveis à forma como os dados são divididos.

O objetivo deste trabalho é construir e avaliar uma árvore de decisão interpretável para identificar pacientes com diabetes nessa base e medir, de forma controlada, o efeito de quatro fatores sobre o seu desempenho: o tamanho da árvore, o tratamento dos valores ausentes, a correção do desbalanceamento entre as classes e a criação de variáveis derivadas. Para o desbalanceamento, optou-se por métodos que não geram amostras sintéticas, como o peso de classe e o ajuste do limiar de decisão, porque pacientes artificiais produzem cortes difíceis de interpretar e porque correções desse tipo distorcem as probabilidades previstas pelo modelo [van den Goorbergh et al. 2022]. As configurações são avaliadas por validação cruzada estratificada repetida e comparadas por um teste t pareado corrigido [Nadeau e Bengio 2003]; entre as que não diferem significativamente da melhor, escolhe-se a mais simples. O modelo escolhido é avaliado uma única vez em um conjunto de teste mantido isolado durante todo o processo.

O restante deste relatório está organizado da seguinte forma: a Seção efsec:base descreve a base de dados e os problemas encontrados nela; a Seção 3 detalha o pipeline de pré-processamento, o protocolo experimental e o teste estatístico; a Seção 4 apresenta e discute os resultados e avalia a robustez do modelo escolhido a outras divisões dos dados; e a Seção 5 traz as conclusões, as limitações e os trabalhos futuros.

2. Base de Dados

A base Pima Indians Diabetes foi coletada pelo National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK), dos Estados Unidos, e descrita em

[Smith et al. 1988]. Ela reúne 768 mulheres de ascendência Pima, com 21 anos ou mais, residentes próximo a Phoenix, no Arizona. Cada paciente é descrita por oito variáveis clínicas, apresentadas na Tabela 1, e pela variável alvo `Outcome`, que indica o diagnóstico de diabetes segundo os critérios da Organização Mundial da Saúde. A base tem 500 pacientes não diabéticas (65,1%) e 268 diabéticas (34,9%), e não contém registros duplicados. O arquivo usado neste trabalho foi obtido no Kaggle, a partir da versão original do UCI Machine Learning Repository.

Tabela 1. Variáveis da base, com o intervalo de valores e a mediana de cada classe. Nas cinco variáveis em que o zero é impossível, a mediana foi calculada sem os zeros.

Variável	Descrição (unidade)	Mín.–Máx.	Mediana		Zeros
			Não diab.	Diab.	
`Pregnancies`	Gestações (número)	0–17	2	4	—*
`Glucose`	Glicose 2 h (mg/dL)	0–199	107	140	0,7%
`BloodPressure`	Pressão diastólica (mmHg)	0–122	70	74,5	4,6%
`SkinThickness`	Prega do tríceps (mm)	0–99	27	32	29,6%
`Insulin`	Insulina 2 h (μU/mL)	0–846	102,5	169,5	48,7%
`BMI`	IMC (kg/m^2)	0–67,1	30,1	34,3	1,4%
`DiabetesPedigreeFunction`	Histórico familiar	0,078–2,42	0,34	0,45	—
`Age`	Idade (anos)	21–81	27	36	—

* Em `Pregnancies`, o zero é um valor válido (14,5% das pacientes).

As medidas de glicose e insulina foram feitas duas horas após a ingestão de glicose, em um teste oral de tolerância à glicose, e não em jejum. A `DiabetesPedigreeFunction` é um índice que resume o histórico de diabetes entre os parentes da paciente [Smith et al. 1988]. A Tabela 1 mostra que as pacientes diabéticas têm medianas maiores em todas as variáveis, com as diferenças mais marcantes no número de gestações, na glicose, na insulina e na idade.

2.1. Problemas encontrados

A análise exploratória revelou três problemas de qualidade nos dados, tratados antes de qualquer experimento.

Zeros que representam valores ausentes. Em `Glucose`, `BloodPressure`, `SkinThickness`, `Insulin` e `BMI`, o valor zero é fisiologicamente impossível e indica que a medida não foi registrada. A proporção de ausentes varia muito entre as variáveis (Tabela 1): é pequena em glicose, pressão e IMC, mas chega a 29,6% na prega cutânea e a 48,7% na insulina. Ao todo, 376 pacientes (49,0%) têm ao menos um valor ausente, de modo que descartar essas linhas reduziria a base à metade. As ausências também não são independentes entre si: todas as 227 pacientes sem a prega cutânea também estão sem a insulina, o que sugere que os dois exames costumavam deixar de ser feitos juntos. A proporção de ausentes é um pouco maior entre as diabéticas (por exemplo, 51,5% contra 47,2% na insulina), mas a diferença é pequena. Por isso, nos experimentos, esses zeros são convertidos em valores ausentes e tratados pelas técnicas descritas na Seção 3.2.

Erro de formatação na `DiabetesPedigreeFunction`. No arquivo obtido, os valores menores que 1 perderam o "0." inicial: o valor 0,627, por exemplo, aparece como 627. O problema atinge 717 das 768 linhas. Como o maior valor real do índice é 2,42, todo valor maior ou igual a 3 só pode ser um desses casos, e a correção, a divisão

por 1000, não tem ambiguidade. Ela é aplicada uma única vez, na geração dos conjuntos de treino e de teste, e o arquivo original é mantido sem alterações.

Desbalanceamento entre as classes. Com 34,9% de pacientes diabéticas, um classificador que sempre prevê a classe "não diabética" já acerta 65,1% dos casos. Por isso, a acurácia não é usada como métrica principal, e o desbalanceamento é tratado como um dos fatores avaliados nos experimentos.

Por fim, a base não passa por tratamento de valores extremos nem por padronização. Como a árvore de decisão compara cada variável com um limiar e, portanto, depende apenas da ordem dos valores, um valor extremo fica do mesmo lado de um corte que um valor apenas alto, e mudanças de escala não alteram as divisões.

3. Metodologia

3.1. Divisão dos dados, validação e avaliação final

A base foi dividida uma única vez, de forma estratificada e com a semente aleatória 42, em um conjunto de treino com 70% das pacientes (537 linhas, 187 diabéticas) e um conjunto de teste com 30% (231 linhas, 81 diabéticas). O conjunto de teste ficou isolado durante todos os experimentos.

As configurações foram avaliadas no conjunto de treino por validação cruzada estratificada com $k = 5$ partições e $r = 5$ repetições, o que gera 25 pares de treino e validação. Com $k = 5$, cada partição de validação tem cerca de 107 pacientes; com $k = 10$, teria cerca de 54, e as notas seriam mais ruidosas. As 25 partições são as mesmas para todas as configurações, o que permite compará-las partição a partição. Todas as etapas que aprendem com os dados, como a imputação, a seleção de variáveis e o ajuste do limiar, são ajustadas apenas nas partições de treino, o que evita o vazamento de informação da validação para o modelo.

Ao fim das rodadas, o modelo escolhido foi treinado com todo o conjunto de treino e avaliado uma única vez no conjunto de teste. Como dezenas de configurações foram comparadas, a nota da melhor na validação cruzada tende a ser otimista, e o teste isolado fornece uma estimativa independente. Por fim, para verificar se os resultados dependem da divisão, a configuração escolhida foi reavaliada, sem alteração dos hiperparâmetros, com outra semente (48) e com a proporção 80/20 (Seção 4.3); essas avaliações não foram usadas para escolher o modelo.

3.2. Pipeline e implementação

Cada configuração é um pipeline com as etapas da Tabela 2, sempre na mesma ordem; cada etapa recebe uma das opções listadas ou é desativada. O modelo é uma árvore de decisão CART, que escolhe, em cada nó, o corte binário que mais reduz a impureza das classes, medida pelo índice de Gini. Como cada corte compara uma variável com um limiar, a árvore depende apenas da ordem dos valores, e por isso não há etapa de padronização nem de tratamento de valores extremos.

No KNN padronizado, as variáveis são padronizadas apenas para calcular a distância entre as pacientes, o que evita que a insulina e a glicose, de valores numericamente maiores, dominem a escolha dos vizinhos; os valores imputados voltam às unidades originais. O produto glicose $\times$ insulina (dividido por 405) é inspirado

Tabela 2. Etapas do pipeline e opções avaliadas em cada uma.

#	Etapa	Opções avaliadas
1	Zeros impossíveis	Converter em ausentes ou manter como valor
2	Indicadores de ausência	Nenhum ou uma coluna binária por variável com ausentes
3	Imputação	Mediana, média, KNN, KNN padronizado, iterativa ou nenhuma (a árvore trata os ausentes)
4	Variáveis derivadas	Nenhuma, produto glicose $\times$ insulina, razões ou faixas de IMC e idade
5	Seleção de variáveis	Nenhuma, k melhores pela estatística F ou RFE
6	Reamostragem	Nenhuma ou subamostragem aleatória da classe majoritária
7	Árvore de decisão	Profundidade, tamanho mínimo da folha, número de folhas, poda, critério e peso de classe
—	Limiar de decisão	Fixo em 0,5 ou ajustado por validação cruzada interna

no índice HOMA-IR, mas não corresponde a ele, que exige medidas em jejum. As razões são insulina/glicose, glicose $\times$ IMC e gestações/idade, e as faixas seguem as categorias de IMC da Organização Mundial da Saúde e intervalos de idade de 10 anos. O limiar de decisão, quando ajustado, é escolhido por uma validação cruzada interna de 5 partições, feita apenas com a partição de treino. Técnicas de sobreamostragem sintética, como o SMOTE, não foram usadas: as pacientes artificiais geram cortes difíceis de interpretar, e correções do desbalanceamento distorcem as probabilidades previstas [van den Goorbergh et al. 2022].

O trabalho foi implementado em Python 3.14, com o scikit-learn 1.9.1 [Pedregosa et al. 2011] e o imbalanced-learn 0.14.2. Cada configuração é descrita em um arquivo YAML (Código 1): o `baseline` define o pipeline de referência, e cada experimento altera etapas com `override` ou gera uma configuração para cada valor de uma lista com `sweep`. Cada execução é salva em uma pasta própria, com a configuração, as notas de cada partição e o modelo treinado.

Código 1. Trecho do arquivo de configuração da rodada R1.

```yaml
baseline:
  zeros: to_nan
  missing_flags: none
  imputer: median
  features: none
  selection: none
  balancing: none
  model: {max_depth: 4}

experiments:
  # Grade profundidade x folha minima (7 x 6 = 42 experimentos)
  - name: R1_grade
    sweep:
      model.max_depth: [2, 3, 4, 5, 6, 8, null]
      model.min_samples_leaf: [1, 5, 10, 20, 30, 50]
```

3.3. Rodadas de experimentos

Os experimentos foram organizados em cinco rodadas (Tabela 3). Cada rodada varia um aspecto do pipeline e parte da configuração escolhida nas anteriores. O tamanho da árvore é ajustado primeiro, por ser o fator de maior impacto, e reajustado no fim, porque os tratamentos dos dados podem mudar onde a árvore faz os cortes.

Tabela 3. Rodadas de experimentos: pergunta, o que varia e critério de escolha.

Rodada	Pergunta	O que varia	Critério
R1	Qual tamanho de árvore generaliza melhor?	Profundidade, folha mínima, número de folhas, poda e critério de divisão	ROC-AUC
R2	Como tratar os valores ausentes?	Conversão dos zeros, imputação e indicadores de ausência	ROC-AUC
R3	Como compensar o desbalanceamento?	Peso de classe, limiar de decisão e subamostragem	F1, com *recall* $\geq 0{,}70$
R4	Variáveis derivadas ajudam?	Variáveis derivadas e seleção de variáveis	ROC-AUC
R5	Os vencedores funcionam juntos?	Pequena grade de tamanho ao redor da configuração combinada	O da rodada que definiu a configuração

R1. Com os zeros convertidos em ausentes e imputados pela mediana, foram avaliadas uma grade de profundidade máxima (2, 3, 4, 5, 6, 8 e sem limite) por tamanho mínimo da folha (1, 5, 10, 20, 30 e 50 amostras), o limite do número de folhas (4 a 24), a entropia no lugar do índice de Gini e a poda por custo-complexidade, que remove os ramos cujo ganho não compensa uma penalidade α por folha (α de 0 a 0,03). **R2.** Foram comparados manter os zeros como valores, a imputação pela mediana, pela média, por KNN (3, 5 e 10 vizinhos), por KNN padronizado e iterativa, deixar a árvore tratar os ausentes e os indicadores de ausência. **R3.** Foram avaliados o peso de classe, que dá às diabéticas um peso maior no cálculo da impureza (balanceado ou 1,5), o ajuste do limiar, a combinação dos dois e a subamostragem da classe majoritária, além de uma grade de tamanho com peso balanceado. Como, em uma triagem, deixar de identificar uma diabética custa mais que um alarme falso, a escolha é feita pelo F1 entre as configurações com *recall* de pelo menos 0,70. **R4.** Foram testados o produto glicose $\times$ insulina, as razões, as faixas e a seleção dos 4 ou 6 melhores atributos pela estatística F e por RFE. **R5.** A combinação dos vencedores foi reavaliada em uma grade 3×3 de profundidade e folha mínima ao redor do seu tamanho.

3.4. Critério de escolha e teste estatístico

A métrica principal é a ROC-AUC, que mede a capacidade do modelo de ordenar as pacientes por risco, independentemente do limiar; a exceção é o R3. Em cada rodada, cada configuração é comparada com a de maior média por um teste t pareado sobre as notas das 25 partições. O teste t comum subestima a variância, porque as partições compartilham dados de treino, e por isso foi usada a correção de [Nadeau e Bengio 2003]:

$$t = \frac{\bar{d}}{\sqrt{\left(\frac{1}{k\,r} + \frac{n_{\text{val}}}{n_{\text{tr}}}\right)\hat{\sigma}_d^2}}, \tag{1}$$

em que $\bar{d}$ e $\hat{\sigma}_d^2$ são a média e a variância das diferenças entre as duas configurações nas 25 partições e $n_{\text{val}}/n_{\text{tr}} = 1/4$. O valor é comparado com a distribuição t de Student com

24 graus de liberdade [Bouckaert e Frank 2004], em um teste bilateral com $\alpha = 0{,}05$. Entre as configurações que não diferem significativamente da melhor, escolhe-se a mais simples, isto é, a árvore menor e com menos etapas de pré-processamento.

4. Resultados e Discussão

Esta seção apresenta primeiro os resultados de cada rodada e do modelo escolhido, incluindo a avaliação no conjunto de teste, depois discute o que eles mostram e, por fim, avalia a robustez do modelo escolhido a outras sementes e proporções de divisão.

4.1. Resultados

Ao todo, foram executadas 101 configurações distintas: 56 no R1, 14 no R2, 21 no R3, 7 no R4 e 3 no R5. As demais configurações previstas no R5 já haviam sido avaliadas no R3 e foram reconhecidas pelo sistema de experimentos, que identifica cada configuração por um código único (*hash*) e não a executa de novo. A Tabela 4 resume cada rodada: a métrica usada, o número de configurações comparadas, quantas não diferem significativamente da melhor, a melhor média e a configuração escolhida pela regra da mais simples (Seção 3.4).

Tabela 4. Resumo das rodadas. "Config." inclui a configuração de partida da rodada, e "Empatadas" conta as configurações sem diferença significativa para a de maior média, incluindo ela própria. Os valores são médias nas 25 partições da validação cruzada.

Rodada	Métrica	Config.	Empatadas	Melhor média	Escolhida
R1	ROC-AUC	56	34	0,790 (prof. 6, folha 20, 19 folhas)	Prof. 3, folha 10, 8 folhas: $0{,}776 \pm 0{,}049$
R2	ROC-AUC	15	15	0,789 (KNN, 10 vizinhos)	Mediana: $0{,}776 \pm 0{,}049$
R3	F1	22	21	0,657 (prof. 4, folha 20, com peso)	Peso balanceado: $0{,}636 \pm 0{,}056$
R4	ROC-AUC	8	8	0,791 (4 melhores pela F)	Sem variáveis novas: $0{,}785 \pm 0{,}049$
R5	F1	9	9	0,657 (prof. 4, folha 20, com peso)	Mantida a do R3: $0{,}636 \pm 0{,}056$

No **R1**, 34 das 56 configurações, com 6 a 33 folhas, não diferiram da melhor. Foi escolhida a árvore com profundidade máxima 3 e folha mínima de 10 amostras (8 folhas, $p = 0{,}49$), com os zeros convertidos em ausentes e imputados pela mediana. No **R2**, nenhuma das 14 alternativas de tratamento dos ausentes diferiu da melhor, e a imputação pela mediana foi mantida ($p = 0{,}62$). No **R3**, todos os tratamentos do desbalanceamento passaram no critério de *recall* mínimo de 0,70 e nenhum diferiu do melhor no F1; a única configuração significativamente pior foi a árvore sem tratamento ($p = 0{,}020$), que também ficou abaixo do *recall* mínimo (0,50). Foi escolhido o peso de classe balanceado na mesma árvore do R1 ($p = 0{,}48$). No **R4**, nenhuma variável derivada nem método de seleção diferiu da configuração de referência ($p \geq 0{,}45$), que foi mantida. No **R5**, nenhuma das 9 configurações da grade diferiu da melhor no F1, e a configuração escolhida no R3 foi mantida.

Modelo escolhido

O modelo final converte os zeros impossíveis em valores ausentes, imputa-os pela mediana e usa uma árvore de decisão com profundidade máxima 3, folha mínima de 10 amostras e peso de classe balanceado. A árvore, treinada com todo o conjunto de treino, é apresentada na Figura 1. Ela tem 8 folhas e usa apenas três variáveis: a glicose (importância 0,60), o IMC (0,25) e a idade (0,15). Lidas como regras, as folhas classificam como diabética a paciente que tem glicose acima de 132,5 mg/dL e IMC acima de 29,95 kg/m^2, ou glicose acima de 151,5 mg/dL com qualquer IMC; e, entre as pacientes com glicose até 132,5 mg/dL, a que tem mais de 29,5 anos e IMC acima de 26,9 kg/m^2, ou até 29,5 anos e IMC acima de 42,8 kg/m^2.

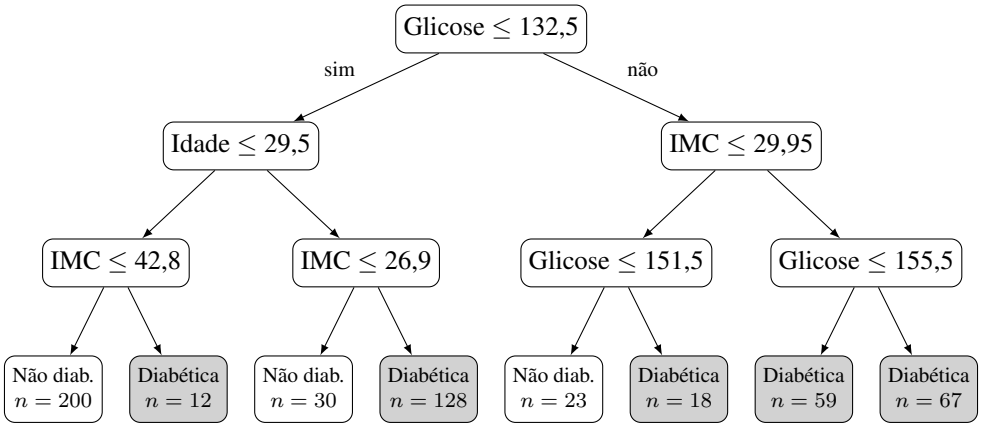


Figura 1. Árvore de decisão escolhida, treinada com o conjunto de treino (537 pacientes). Em cada nó, o ramo da esquerda corresponde à condição verdadeira. As folhas indicam a classe prevista e o número de pacientes de treino; as folhas em cinza são classificadas como diabéticas.

Avaliação no conjunto de teste

O modelo escolhido foi avaliado uma única vez no conjunto de teste, com 231 pacientes, das quais 81 diabéticas. A Tabela 5 compara as métricas do teste com as médias da validação cruzada, e a Tabela 6 mostra a matriz de confusão. No teste, o modelo identificou 65 das 81 diabéticas (*recall* de 0,802) e classificou corretamente 105 das 150 não diabéticas (especificidade de 0,700). Das 110 pacientes classificadas como diabéticas, 65 de fato eram (precisão de 0,591), e das 121 classificadas como não diabéticas, 105 de fato não eram (valor preditivo negativo de 0,868).

4.2. Discussão

Tamanho da árvore (R1). Os dois extremos de complexidade perderam com significância: sem limite de crescimento, a árvore memoriza o treino (98 folhas, AUC 0,663, $p < 0{,}001$), e as árvores de profundidade 2 e as podas mais fortes ficaram abaixo da melhor. Entre eles, 34 configurações, de 6 a 33 folhas, não diferem da melhor, e a maior diferença de média nessa faixa (0,023) é menor que o desvio-padrão entre partições (0,04 a 0,05). Como a fronteira da significância se mostrou instável entre as árvores menores, a

Tabela 5. Métricas do modelo escolhido na validação cruzada (média e desvio-padrão nas 25 partições) e no conjunto de teste.

Métrica	Validação cruzada	Teste
ROC-AUC	$0{,}785 \pm 0{,}049$	0,790
Recall	$0{,}786 \pm 0{,}120$	0,802
Precisão	$0{,}543 \pm 0{,}049$	0,591
F1	$0{,}636 \pm 0{,}056$	0,681
Acurácia balanceada	$0{,}713 \pm 0{,}046$	0,751
Acurácia	$0{,}690 \pm 0{,}046$	0,736

Tabela 6. Matriz de confusão do modelo escolhido no conjunto de teste.

	Previsto não diabética	Previsto diabética
Não diabética (150)	105	45
Diabética (81)	16	65

escolha recaiu sobre a mais simples fora dessa zona (profundidade 3, folha mínima 10, 8 folhas).

Valores ausentes (R2). Nenhuma forma de imputação diferiu da melhor, e variações da mesma ordem surgiram só de trocar o número de vizinhos do KNN, o que indica diferenças no nível do ruído. A imputação, porém, muda as variáveis usadas: com o KNN, a árvore passa a cortar na insulina, imputada em cerca de metade das pacientes, o que mistura valores medidos e estimados em uma mesma regra; com a mediana, ela usa apenas glicose, IMC e idade, quase sem ausentes. Os indicadores de ausência não tiveram efeito (diferença de no máximo 0,0004 na AUC) e nunca foram usados pela árvore, o que é coerente com a falta de associação entre a ausência dos exames e o diagnóstico no treino (36% e 34% de diabéticas entre as pacientes com e sem insulina, $p = 0{,}53$).

Desbalanceamento (R3). Peso de classe, ajuste do limiar e subamostragem tiveram resultados equivalentes, e todos superaram o *recall* mínimo, enquanto a árvore sem tratamento identifica só metade das diabéticas. Na mesma árvore, o peso balanceado elevou o *recall* de 0,50 para 0,79 ($p < 0{,}001$) e reduziu a precisão de 0,70 para 0,54, sem mudança significativa no F1, na acurácia balanceada e na AUC. O peso não altera os cortes da árvore, apenas a classe de duas folhas, o que equivale a baixar o limiar de decisão e explica por que as duas técnicas empatam.

Variáveis derivadas (R4). Nenhuma variável nova nem método de seleção melhorou a árvore, que já faz a sua própria seleção: com as faixas, a seleção pelos 6 melhores atributos ou a RFE, ela continua usando glicose, IMC e idade. Algumas alternativas pioraram a interpretação ou o *recall*: o produto glicose $\times$ insulina vira a raiz da árvore, mas funciona como um corte de glicose disfarçado, já que metade das insulinas é imputada; e as razões empatam na AUC, mas reduzem o *recall* para 0,66, abaixo do mínimo, o que mostra que olhar apenas a métrica da rodada não basta.

Combinação (R5). A árvore de profundidade 2 empatou no F1 e seria a mais simples, mas ficou abaixo do *recall* mínimo (0,60). O terceiro nível é o que recupera as diabéticas: ele divide pelo IMC o grupo com glicose até 132,5 e idade acima de 29,5 anos, que na árvore menor é uma única folha classificada como não diabética.

Generalização e limites da comparação. No teste, todas as métricas ficaram

dentro de um desvio-padrão das médias da validação cruzada (Tabela 5), sem sinal de sobreajuste à seleção, provavelmente porque a regra da configuração mais simples evitou escolher a de maior média. Para uma triagem, o resultado negativo é o mais confiável, enquanto cerca de 4 em cada 10 alarmes são falsos e exigem exames confirmatórios. Por fim, $p \geq 0{,}05$ indica ausência de evidência de diferença, e não equivalência: com 25 partições correlacionadas, o teste tem pouco poder para diferenças pequenas.

4.3. Robustez à semente e à divisão dos dados

A configuração escolhida foi treinada e avaliada novamente, sem alteração dos hiperparâmetros, em três cenários adicionais (semente 42 com divisão 80/20 e semente 48 com divisões 70/30 e 80/20), refazendo em cada um a divisão, a validação cruzada, o treino e o teste (Tabela 7). Na validação cruzada, a ROC-AUC variou de 0,768 a 0,803, amplitude menor que o desvio-padrão entre as partições de cada cenário, e o cenário principal teve o menor *recall* e o menor F1, portanto não foi favorecido pela divisão. No teste, a variação foi maior (AUC de 0,784 a 0,855), como esperado para conjuntos de 154 ou 231 pacientes; a AUC de 0,855 fica cerca de dois desvios-padrão acima da validação do mesmo cenário, o que indica um conjunto de teste mais fácil, e não um modelo melhor. Em nenhum cenário o teste ficou bem abaixo da validação.

Tabela 7. Modelo escolhido em quatro cenários de semente e divisão. Na validação cruzada (VC), média e desvio-padrão nas 25 partições. A primeira linha é o cenário principal.

		VC		Teste			
Cenário	Treino/Teste	AUC	*Recall*	AUC	*Recall*	Precisão	F1
42, 70/30	537/231	$0{,}785 \pm 0{,}049$	$0{,}786 \pm 0{,}120$	0,790	0,802	0,591	0,681
42, 80/20	614/154	$0{,}803 \pm 0{,}038$	$0{,}834 \pm 0{,}070$	0,784	0,852	0,529	0,652
48, 70/30	537/231	$0{,}771 \pm 0{,}047$	$0{,}808 \pm 0{,}081$	0,809	0,840	0,553	0,667
48, 80/20	614/154	$0{,}768 \pm 0{,}041$	$0{,}800 \pm 0{,}072$	0,855	0,889	0,539	0,671
Amplitude	—	0,034	0,047	0,071	0,086	0,062	0,028

O comportamento do modelo se manteve em todos os cenários: *recall* no teste acima de 0,80, precisão entre 0,53 e 0,59 e valor preditivo negativo entre 0,87 e 0,91. As quatro árvores têm 8 folhas e as mesmas regras, baseadas em glicose, IMC e idade, mudando apenas alguns limiares, como o corte da glicose na raiz (127,5 ou 132,5). O modelo é, portanto, robusto à semente e à proporção da divisão, e os números de teste do cenário principal devem ser lidos como uma estimativa entre valores plausíveis (AUC de 0,78 a 0,86 e *recall* de 0,80 a 0,89), e não como valores exatos.

5. Conclusão

Este trabalho construiu uma árvore de decisão interpretável para a triagem de diabetes na base Pima Indians Diabetes, comparando de forma controlada o tamanho da árvore, o tratamento dos ausentes, a correção do desbalanceamento e a criação de variáveis. O modelo final é uma árvore de profundidade 3, com 8 folhas, que usa apenas glicose, IMC e idade e identificou 65 das 81 diabéticas do teste (*recall* de 0,80, ROC-AUC de 0,79), com resultados estáveis entre a validação cruzada, o teste e outras divisões dos dados. Os experimentos indicam que, nesta base, escolher bem o tamanho da árvore e o critério de decisão importa mais que sofisticar o pré-processamento: imputação, variáveis derivadas

e seleção não trouxeram ganhos, enquanto o peso de classe elevou o *recall* de 0,50 para 0,79 sem alterar as regras.

Os resultados têm limitações: a base é pequena e representa uma única população; a insulina tem quase metade de ausentes; o teste estatístico tem pouco poder para diferenças pequenas; e o processo de seleção foi feito com uma única divisão, tendo sido reavaliada com outras divisões apenas a configuração escolhida. Como trabalhos futuros, propõe-se repetir todo o processo de seleção em várias divisões, validar o modelo em outras populações e compará-lo com modelos de maior capacidade, para medir quanto desempenho se perde em troca da interpretabilidade.

Referências

Bouckaert, R. R. e Frank, E. (2004). Evaluating the replicability of significance tests for comparing learning algorithms. In *Advances in Knowledge Discovery and Data Mining (PAKDD 2004)*, volume 3056 of *Lecture Notes in Computer Science*, pages 3–12. Springer.

Nadeau, C. e Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3):239–281.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., e Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. In *Proceedings of the Annual Symposium on Computer Application in Medical Care*, pages 261–265.

van den Goorbergh, R., van Smeden, M., Timmerman, D., e Van Calster, B. (2022). The harm of class imbalance corrections for risk prediction models: illustration and simulation using logistic regression. *Journal of the American Medical Informatics Association*, 29(9):1525–1534.